

Python による異常検知
正誤表

ページ	該当箇所	誤	正
vi	目次 第2章 2.5 タイトル	関数近似に基づく <u>値</u> 異常検知	関数近似に基づく異常検知
11	1.1-2 章 第1段落 3 行目 (下から 9 行目)	多数のサンプルデータの入力セ ット \mathbf{x}_i とラベルセット \mathbf{i} , $i =$ $1, 2, 3 \dots N$ がある場合	多数のサンプルデータの入力 セット \mathbf{x}_i とラベルセット \mathbf{d}_i , $i =$ $1, 2, 3 \dots N$ がある場合
19	1 行目	① 目的の違い	目的の違い
23	図 1.6 右側	<u>不正解</u> : 1	正解 : 1
23	第2段落 2 行目 (上から 5 行目)	訓練データ \mathbf{x}_i を用いて誤差関数 の総和を <u>最小</u> になるように	訓練データ \mathbf{x}_i を用いて誤差関数 の総和が <u>最小</u> になるように
24	図 1.7 下段 右から 2 番目	ε -不感 <u>損失</u> 関数	ε -不感 <u>誤差</u> 関数
26	① 第1段落 2 行目	\mathbf{x} は説明変数を、 \mathbf{n} は説明変数の 数を表しています。	\mathbf{x} は説明変数を、 \mathbf{K} は説明変数の 数を表しています。
27	(b) 第1段落 2 行目	さらに説明変数 \mathbf{x} を <u>$f(\mathbf{x})$</u> に拡張す ることによって	さらに説明変数 \mathbf{x} を <u>$\varphi(\mathbf{x})$</u> に拡張す ることによって
30	第2段落 4 行目	誤差 $\delta_i = f(\mathbf{x}) - y_i$ ($\xi_i \geq 0$)を最 小にするのが一般的です。	誤差 $\delta_i = f(\mathbf{x}_i) - y_i $ ($\delta_i \geq 0$)を 最小にするのが一般的です。
30	第3段落 2 行目	マージン $m_i = f(\mathbf{x})y_i = (w\mathbf{x}_i +$ $b)y_i$ として展開することができるので	マージン $m_i = f(\mathbf{x}_i)y_i = (w\mathbf{x}_i +$ $b)y_i$ として展開することができる ので
30	式(13)	$\max \{d\} = \min \left\{ \frac{1}{2} w \right\}$ $\equiv \min \left\{ \frac{1}{2} w ^2 \right\}$ $\equiv \min \left\{ \frac{1}{2} w ^2 + C \sum_{i=1}^N \delta_i \right\}$	$\max[d] = \min[w] :$ $\Leftrightarrow \min \left[\frac{1}{2} w ^2 \right] :$ $\Leftrightarrow \min \left[\frac{1}{2} w ^2 + C \sum_{i=1}^N \delta_i \right]$
30	式(14)	$\min \left\{ \frac{1}{2} w ^2 + C \sum_{i=1}^N \delta_i \right\}$	$\min \left[\frac{1}{2} w ^2 + C \sum_{i=1}^N \delta_i \right]$
33	式(22)と式(23)	$\min \{1, \max(0, 1 - m_i)\}$	$\min \{1, \max(0, 1 - m_i)\}$
35	式(25)	$0, \delta_i \leq \varepsilon$	$0, \delta_i < \varepsilon$

35	式(25)後の1行目	ここでは $\delta_i = f(x) - y_i$ とします。	ここでは $\delta_i = f(x_i) - y_i$ とします。
ページ	該当箇所	誤	正
35	(式 25)	$L = \begin{cases} 0, & \delta_i \leq \varepsilon \\ \delta_i - \varepsilon, & \delta_i \geq \varepsilon \end{cases}$	$L = \begin{cases} 0, & \delta_i \leq \varepsilon \\ \delta_i - \varepsilon = \xi, & \delta_i \geq \varepsilon \end{cases}$
42	(a) 第2段落 3行目	重複ありで m 個 ($m \leq n$) のデータをランダムに抜き出して、	重複ありで m 個 ($m \leq n$) のデータをランダムに抜き出して、
45	式(28)	$\sum_{i=1}^N w_i^{(m-1)} \dots$	$\sum_{i=1}^N w_i^{(m-1)} \dots$
46	図 1.24 上部の表 2段目 (両列)	$\sum_{i=1}^N w_i^{(m-1)} \dots$	$\sum_{i=1}^N w_i^{(m-1)} \dots$
46	図 1.24 上部の表 3段目 (左列)	$\gamma_m = \frac{\overline{e_m}}{1 - \overline{e_m}}$	$\gamma_m = \frac{\overline{e_m}}{1 - \overline{e_m}}$
46	図 1.24 上部の表 2段目と4段目 (両列)	$h^m(x_i; a)$	$h^m(x_i; a)$
46	最終行	係数 γ_i を規格してから	係数 γ_i を規格化してから
48	図 1.25 上部の表 4段目と5段目	$h^m(x_i; a)$	$h^m(x_i; a)$
48	2行目	各データ (x_i, y_i) についての損失関数 $L(y_i, F(x_i))$ を小さくすることを考えましょう。	各データ (x_i, y_i) についての誤差関数 $L(y_i, F(x_i))$ を小さくすることを考えましょう。
49	式(35)	$F_{m_{m-1}}(X) + \gamma h^m(x_i; \alpha_m)$	$F_m(X) = F_{m-1}(X) + \gamma h^m(x_i; \alpha_m)$
52	式(44)	$\frac{\sum_{i=1}^N g_i}{\sum_{i=1}^N h_i + \lambda}$	$\frac{\sum_{i=1}^N g_i}{\sum_{i=1}^N h_i + \lambda}$
53	式(46)	$y \ln P$	$y \ln p$
55	式(48)	(M, n, d_{new})	(M, N, d_{new})
55	式(49)	$\begin{bmatrix} x_{\pi_1^{(k)}(1)} & \cdots & x_{\pi_1^{(k)}(p)} \\ x_{\pi_2^{(k)}(1)} & \cdots & x_{\pi_2^{(k)}(p)} \\ \vdots & \cdots & \vdots \\ x_{\pi_N^{(k)}(1)} & \cdots & x_{\pi_N^{(k)}(p)} \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ w_1 \\ \vdots \\ w_p \end{bmatrix}$	$\begin{bmatrix} x_{\pi_1^{(k)}(1)} & \cdots & x_{\pi_1^{(k)}(p)} \\ x_{\pi_2^{(k)}(1)} & \cdots & x_{\pi_2^{(k)}(p)} \\ \vdots & \cdots & \vdots \\ x_{\pi_N^{(k)}(1)} & \cdots & x_{\pi_N^{(k)}(p)} \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_p \end{bmatrix}$
58	式(50)後 第2段落 3行目 URL	https://www.kaggle.com/c/Merck Activity (スペースあり)	https://www.kaggle.com/c/MerckActivity (スペースなし)
63	図 1.34 右	6次元グラフの座標軸で、 p 軸が2つ存在	片方を q 軸へ変更

66	式(58)、式(59、式(60)、式(61)	F^t	F^T
66	最終行	共分散行列 \underline{XX}^t の固有関数行列です。	共分散行列 \underline{XX}^T の固有関数行列です。
67	第 1 段落 5 行目	また、 $\underline{X_iX_i}^t$ は式(64)の条件を満たしているので、	また、 $\underline{X_iX_i}^T$ は式(64)の条件を満たしているので、
ページ	該当箇所	誤	正
66	図 1.38 ① 下	XX^t	XX^T
66	図 1.38 ③	$\begin{pmatrix} f_{11} & f_{21} & f_{31} & f_{41} & f_{51} & f_{61} \\ f_{12} & f_{22} & f_{33} & f_{44} & f_{55} & f_{66} \end{pmatrix}$	$\begin{pmatrix} f_{11} & f_{21} & f_{31} & f_{41} & f_{51} & f_{61} \\ f_{12} & f_{22} & f_{32} & f_{42} & f_{52} & f_{62} \end{pmatrix}$
74	第 3 段落 2 行目	t-SNE 手法では Embeding 、	t-SNE 手法では Embedding 、
76	第 2 段落 4 行目	それは KL カルバック・ライブラー情報量 (KL ダイバージェンス) です。	それは カルバック・ライブラー情報量 (KL ダイバージェンス) です。
77	図 1.43 下部の数式	$L = KL\{p_{ij}(2D), q_{ij}(1D)\} \rightarrow 0$ $z_i \leftarrow z_i + a \frac{\delta L}{\delta z_i}$	$L = KL\{p_{ij}(2D) q_{ij}(1D)\} \rightarrow 0$ $z_i \leftarrow z_i + a \frac{\delta L}{\delta z_i}$
81	図 1.45 ネットワーク部分、右側ノードの一番下	y_3	y_7
81	② の式	$\begin{cases} = 1 & (i = i_{winner}) \\ = 0 & (i \neq i_{winner}) \end{cases}$	$\begin{cases} 1 & (i = i_{winner}) \\ 0 & (i \neq i_{winner}) \end{cases}$
82	図 1.46 ネットワーク部分、右側ノードの一番下	c_7	c_n
85	式(84) 1 行目	$\begin{cases} = 1 & (i = i_{winner}) \\ = 0 & (i \neq i_{winner}) \end{cases}$	$\begin{cases} 1 & (i = i_{winner}) \\ 0 & (i \neq i_{winner}) \end{cases}$
86	第 1 段落 2 行目	<u>K</u> 平均法の計算プロセスとまったく同じです。	<u>k</u> 平均法の計算プロセスとまったく同じです。
88	図 1.50 (c) Resampling 部分	$x_1^{resampe}$	$x_1^{resample}$
88	第 3 段落 1 行目	<u>規格</u> された尤度関数を重み w として定義します。	<u>規格化</u> された尤度関数を重み w として定義します。
94	第 2 段落 2 行目	1.4 節で説明した主成分分析や <u>K</u> 平均法、	1.4 節で説明した主成分分析や <u>k</u> 平均法、
95	式(1)	$\alpha = -\ln(p(x' D, \theta))$	$\alpha = -\ln(p(x' D, \theta))$

95		この μ はデータの平均値、 σ はデータの分散値として知られています	この μ はデータの平均値、 σ^2 はデータの分散値として知られています
96		ただし、式(2)の分母には分散 σ が入っています。分散 σ の効果は、同図の左側のグラフに示しています。たとえば分散 σ が小さい場合では、データの正規分布も異常度 α の分布も鋭くなります。直感的にいうと、平均との距離 $ x - \mu $ が同じである2つのデータ点に関しては、小さい分散 σ をもつデータの異常度 α が高いという結果になります。これは数学的に式(2)で検証すれば自明なことです。	ただし、式(2)の分母には分散 σ が入っています。分散 σ^2 の効果は、同図の左側のグラフに示しています。たとえば分散 σ^2 が小さい場合では、データの正規分布も異常度 α の分布も鋭くなります。直感的にいうと、平均との距離 $ x - \mu $ が同じである2つのデータ点に関しては、小さい分散 σ^2 をもつデータの異常度 α が高いという結果になります。これは数学的に式(2)で検証すれば自明なことです。
103	式(11)	$-\ln(p(\mathbf{x}' D, \theta))$	$-\ln(p(\mathbf{x}' D, \theta))$
103	式(11)後 1 行目	式(11)において、 Σ は分散行列であり、	式(11)において、 Σ は <u>共分散</u> 行列であり、
103	最終行	分散行列を下記の3種類と仮定します。	<u>共分散</u> 行列を下記の3種類と仮定します。
104	① タイトル	分散行列 1	<u>共分散</u> 行列 1
104	式(12)後 1 行目	分散行列の対角要素は定数 1 になっているので、	<u>共分散</u> 行列の対角要素は定数 1 になっているので、
ページ	該当箇所	誤	正
104	式(14)	$\alpha(\mathbf{S}_1) = \{(s_1^x - u^x)^2 + (s_1^y - u^y)^2 + \dots (s_1^T - u^T)^2\}$	$\alpha(\mathbf{S}_1) = \{(s_1^x - u^x)^2 + (s_1^y - u^y)^2 + \dots (s_1^T - u^T)^2\}$
104	式(15)	$\alpha(\mathbf{S}_2) = \{(s_2^x - u^x)^2 + (s_2^y - u^y)^2 + \dots (s_2^T - u^T)^2\}$	$\alpha(\mathbf{S}_2) = \{(s_2^x - u^x)^2 + (s_2^y - u^y)^2 + \dots (s_2^T - u^T)^2\}$
104	②タイトル	分散行列 2	<u>共分散</u> 行列 2
104	式(16)後 1 行目	分散行列の逆行列は、	<u>共分散</u> 行列の逆行列は、

104	式(18)	$\alpha(S_1) = \left\{ \frac{(\bar{s}_1^X)^2}{a} + \frac{(\bar{s}_1^Y)^2}{b} + \frac{(\bar{s}_1^Z)^2}{c} + \frac{(\bar{s}_1^T)^2}{d} \right\}$	$\alpha(S_1) = \left\{ \frac{(\bar{S}_1^X)^2}{a} + \frac{(\bar{S}_1^Y)^2}{b} + \frac{(\bar{S}_1^Z)^2}{c} + \frac{(\bar{S}_1^T)^2}{d} \right\}$
104	式(19)	$\alpha(S_2) = \left\{ \frac{(\bar{s}_2^X)^2}{a} + \frac{(\bar{s}_2^Y)^2}{b} + \frac{(\bar{s}_2^Z)^2}{c} + \frac{(\bar{s}_2^T)^2}{d} \right\}$	$\alpha(S_2) = \left\{ \frac{(\bar{S}_2^X)^2}{a} + \frac{(\bar{S}_2^Y)^2}{b} + \frac{(\bar{S}_2^Z)^2}{c} + \frac{(\bar{S}_2^T)^2}{d} \right\}$
105	③タイトル	分散行列 3	<u>共</u> 分散行列 3
105	1 行目	以下の構造を持つ分散行列が多 くみられます。	以下の構造を持つ <u>共</u> 分散行列が 多くみられます。
105	式(20)後 1 行目	分散行列の逆行列を簡単に計算 することはできません。	<u>共</u> 分散行列の逆行列を簡単に計 算することはできません。
105	図 2.8 後 1 行目	算出した分散行列Σと、	算出した <u>共</u> 分散行列Σと、
106	第 4 段落 3 行目	分散行列の逆行列は np.linalg.inv()を用いて簡単に計 算することができます。	<u>共</u> 分散行列の逆行列は np.linalg.inv()を用いて簡単に計 算することができます。
107	式(24)	$SN \equiv 10 \log 10\{\dots\}$	$SN \equiv 10 \log_{10}\{\dots\}$
108	式(25)	$SN = 10 \log 10\{\dots\}$	$SN = 10 \log_{10}\{\dots\}$
P111	式(26)	$\alpha = \frac{1}{k} \frac{\sum_{i=1}^k -q_i }{\sum_{i=1}^N q_{i,k} - x_i }$	$\alpha = \frac{1}{k} \frac{\sum_{i=1}^k p - q_i }{\sum_{i=1}^N q_{i,k} - x_i }$
117	式(29)	$\alpha(x) = -\ln \left\{ \sum_{k=1}^K \pi_k N\{x \mu_K, \Sigma_k\} \right\}$	$\alpha(x) = -\ln \left\{ \sum_{k=1}^K \pi_k N\{x \mu_k, \Sigma_k\} \right\}$
117	式(29)後 1 行目	ここでの $\pi_k, \underline{\mu}_k, \Sigma_k$ はそれぞれ、	ここでの $\pi_k, \underline{\mu}_k, \Sigma_k$ はそれぞれ、
118, 119	式(31)、式(32)、式(33)	$F^t F X$	$F^T F X$
121	2.5 章 タイトル	関数近似に基づく <u>値</u> 異常検知	関数近似に基づく異常検知
121, 123	最下部 2.5 章 タイトル	関数近似に基づく <u>値</u> 異常検知	関数近似に基づく異常検知
122	式(43)後 1 行目	ここで、 $\underline{\delta}_i = f(x) - d_i$ ($\xi_i \geq$ <u>0</u>)、 <u> </u>	ここで、 $\underline{\delta}_i = f(x_i) - d_i$ ($\delta_i \geq$ <u>0</u>)、 <u> </u>
124	式(48)	$\alpha(X_{test}) == [\alpha(X_{test})$ $\quad - \tilde{f}(X_{test})]^2$	$\alpha(X_{test}) = [\alpha(X_{test}) - \tilde{f}(X_{test})]^2$
126	図 2.16 要素①の式	$N_{\text{止} \rightarrow \text{正}}^{\text{予}} = 15$	$N_{\text{正} \rightarrow \text{正}}^{\text{予}} = 15$
ページ	該当箇所	誤	正
133, 135	図 2.19 と図 2.20 下のグラ フ	Area <u> </u> under Curve (AUC)	Area <u> </u> Under Curve (AUC)
141	図 3.1 x_4 における観測値	$y_s(x_1)$	$y_s(x_4)$

143	① (2) 1 行目	時系列サンプル観測値 $y(t)y(t)$ の分散は、	時系列サンプル観測値 $y(t)$ の分散は、
143	① (3) 1 行目	時系列サンプル観測値 $y(t)y(t)$ と	時系列サンプル観測値 $y(t)$ と
144	② (2) 2 行目	残差に対する偏自己相関 (ACF) があります。	残差に対する偏自己相関 (PACF) があります。
160	3.2-4 章 第 3 段落 1 行目	事前に決めなければいけないハイパーパラメータ (p, q) が 3 つありますが、	事前に決めなければいけないハイパーパラメータは (p, q) の 2 つがありますが、
164	式(20) 1 行目	$\Delta^1 s_t = s_t - s_t$	$\Delta^1 s_t = s_t - s_{t-1}$
174	式(28)	$\hat{x}_t = (1 - k)\hat{x}_t + k_t \cdot x_t$	$\hat{x}_t = (1 - k_t)\hat{x}_t + k_t \cdot x_t$
176	式(40)	$\sigma^2_{\hat{x}_t} = (1 - k)(a^2 \sigma^2_{\hat{x}_{t-1}} + g^2 \tau^2)$	$\sigma^2_{\hat{x}_t} = (1 - k_t)(a^2 \sigma^2_{\hat{x}_{t-1}} + g^2 \tau^2)$
177	図 3.22 時刻= $t + 1$ 部分	$\hat{x}_{t+1} = a\hat{x}_t + d = g\epsilon_t$	$\hat{x}_{t+1} = a\hat{x}_t + d + g\epsilon_{t+1}$
178	式(53)後 1 行目	カルマン <u>ケ</u> インおよび分散の更新は、	カルマン <u>ゲ</u> インおよび分散の更新は、
179	式(60)後 1 行目	時刻 t におけるフィルタリングとカルマン <u>ケ</u> イン、	時刻 t におけるフィルタリングとカルマン <u>ゲ</u> イン、
190	図 3.28 2 段目 タイトル	SVM	SVR
191	第 2 段落 7 行目(下から 3 行目)	このことはランダムフォレストと同じ種類の手法、	このことはランダムフォレストと同じ種類の手法、
193	第 1 段落と ADF 検定結果	文章と結果が異なっている (文章は 151 ページのコピー ?)	?
194	リスト 3.25 189 行目	<code>pyplot.show()</code>	<code>plt.show()</code>
196	式(67)	$\alpha(X_t) = X_t - \tilde{X}_t(In-sample) $	$\alpha(X_t) = X_t - \tilde{X}_t(In_sample) $
197	式(68)	$\alpha(X_t) = X_t - \tilde{X}_t(Out-sample) $	$\alpha(X_t) = X_t - \tilde{X}_t(Out_sample) $
207	2 第 1 段落 2 行目	それぞれ $K=1$ と $K>1$ の概念図を示しています。	それぞれ $k=1$ と $k>1$ の概念図を示しています。
218	図 3,49 (c) タイトル	<code>Jinear_Regression</code>	<code>Linear_Regression</code>
222	リスト 4.1 タイトル	<code>AutoEncoder.ipynb</code>	<code>AutoEncoder.py</code>
ページ	該当箇所	誤	正
224	リスト 4.3 タイトル	<code>AutoEncoder.ipynb</code>	<code>AutoEncoder.py</code>
231	リスト 4.5 タイトル	<code>anoGAN.ipynb</code>	<code>anoGAN.py</code>

233	STEP4 タイトル	<u>損失</u> の導入	<u>誤差関数</u> の導入
233	第 1 段落 4 行目	次の 2 つの <u>損失</u> を導入します。	次の 2 つの <u>誤差関数</u> を導入します。
234	リスト 4.6 タイトル	anoGAN. <u>ipynb</u>	anoGAN. <u>py</u>
235	4.1-4 章 第 2 段落 1 行目	長さ <u>d</u> の時系列データから、次の <u>l</u> 個の観測値を予測する LSTM を学習します。図 4.12 は、 <u>$d = 2, l = 1$</u> の場合です。	長さ <u>d</u> の時系列データから、次の <u>l</u> 個の観測値を予測する LSTM を学習します。図 4.12 は、 <u>$d = 2, l = 1$</u> の場合です。
236	STEP1 第 1 段落 1 行目	LSTM は長さ <u>d</u> の時系列データから次の <u>l</u> 個を予測するので、	LSTM は長さ <u>d</u> の時系列データから次の <u>l</u> 個を予測するので、
236	STEP1 第 1 段落 4 行目	今回は <u>$d = 10, l = 3$</u> としてデータセットを生成します。	今回は <u>$d = 10, l = 3$</u> としてデータセットを生成します。
236	リスト 4.7 タイトル	LSTM. <u>ipynb</u>	LSTM. <u>py</u>
237	STEP2 第 2 段落 1 行目	テストデータの <u>損失関数</u> の値をそれぞれプロットし、	テストデータの <u>誤差関数</u> の値をそれぞれプロットし、
237	リスト 4.8 タイトル	LSTM. <u>ipynb</u>	LSTM. <u>py</u>
240	第 1 段落 2 行目	<u>M</u> 次元正規分布にフィッティングした最尤推定量の値は、	<u>M</u> 次元正規分布にフィッティングした最尤推定量の値は、
240	リスト 4.9 タイトル	LSTM. <u>ipynb</u>	LSTM. <u>py</u>
241	リスト 4.10 タイトル	LSTM. <u>ipynb</u>	LSTM. <u>py</u>
260	索引 E 3 行目	Embedding	Embedding
260	索引 K 2 行目	<u>Kl</u> カルバック・ライブラー情報量	カルバック・ライブラー情報量

P 193

修正前

以下は ADF 検定結果です。P 値が非常に大きいので、サンプルデータは非定常性をもつことが示唆されます。さらに ADF 統計値の -0.773461 は、すべての臨界値 (Critical Values) より大きくなっており、非定常性であることが示唆されます。

ADF Statistic: -3.105539 P-value: 0.026146

Critical Values: 1%: -3.448 5%: -2.869 10%: -2.571

修正後

以下は ADF 検定結果です。P 値が **0.026146** となっています。この数値は非常に微妙です。仮に基準の P 値が **0.05** とすれば単位根過程という帰無仮説は棄却されるので、単位根過程ではないとみなすことができます。しかし基準の P 値が **0.01** とすると、単位根過程という帰無仮説は棄却できません。ADF 統計値も同じ傾向を示しています。臨界値を **5%** とした場合は、ADF 統計値の **-3.105539** が臨界値を下回るので、定常性であるとみなせますが、臨界値を **1%** とした場合は、ADF 統計値のほうが臨界値を上回るので、定常性ではなく非定常性であることが示唆されます。

P 214

(修正前)

また、証明は省略しますが、 $\Sigma_{5 \times 5}$ の要素 σ の値は A の固有値の平方根となり、数値 1 より小さくなります。特異スペクトル変換法は最大特異値である σ_1 を用いて、異常度を以下のように定義しています。

$$\alpha = 1 - \sigma_1^2 \quad (82)$$

(修正後)

また、証明は省略しますが、 $\Sigma_{5 \times 5}$ の要素 σ の値は A の固有値の平方根となり、数値 1 より小さくなります。誤差関数とのつながりから、式(78)の単位行列 I を正解とみなせば、異常度は正解との誤差から定義することができます。ただし、式(80)は複数個の特異値を持つので、文献[33]で紹介した複数個の特異値の中の最大特異値である σ_1 を用いて、以下のように異常度を計算します。

$$\alpha = 1 - \sigma_1^2$$